



Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

Procesamiento de Lenguaje Natural

Procesamiento Básico

Mauricio Toledo-Acosta
mauricio.toledo@unison.mx

Departamento de Matemáticas
Universidad de Sonora



Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

Section 1

Expresiones regulares



Expresiones regulares

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

Una **expresión regular** (regex, expresión racional) es una secuencia de caracteres que especifica un patrón de coincidencia en un texto. Los algoritmos de búsqueda de cadenas suelen utilizar este tipo de patrones para realizar operaciones de "búsqueda" o "búsqueda y sustitución" de cadenas, o para validar entradas.

Las expresiones regulares constan de constantes (denotan conjuntos de cadenas) y símbolos de operaciones (denotan operaciones sobre estos conjuntos).



Un poco de historia

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización


POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

Se originaron en 1951, por Stephen Cole Kleene. Usualmente se usa el standard IEEE POSIX. Kleene es uno de los fundadores de las ciencias computacionales teóricas.





Utilidad de las expresiones regulares

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

- Validación de datos.
- Búsqueda, extracción y reemplazo de texto.
- División de Texto
- Transformación de Texto.
- Tareas de PLN (eliminación de stopwords).



Referencias adicionales

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

- <https://regex101.com/>
- Tutorial 1.
- Tutorial 2.
- Tutorial 3.



Tutorial: Metacaracteres

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización
Lematización
POS tagging
Parsing
Name Entity
Recognition (NER)

Tarea

Los metacaracteres son caracteres que un motor RegEx interpreta de forma especial

[. ^ \$ * + ? { } \ |

[]	Cualquier caracter dentro de los corchetes
.	Cualquier caracter (excepto cambios de línea)
^	Buscar si el caracter siguiente está al inicio de una línea
[^]	Negación de cualquier caracter dentro de los corchetes
\$	Buscar si el caracter anterior está al final de una línea

Si queremos buscar los metacaracteres como caracteres se anteceden de un \.



Tutorial: Metacaracteres

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

`[].^$*+?{}()\|`

<code>*</code>	Busca si el caracter anterior ocurre 0 o más veces
<code>+</code>	Busca si el caracter anterior ocurre 1 o más veces
<code>?</code>	Busca si el caracter anterior ocurre 0 o 1 vez
<code>{m, n}</code>	Busca si el caracter anterior ocurre al menos m veces y máximo n veces
<code> </code>	OR, busca el caracter antes o después del
<code>()</code>	Agrupar patrones (expresiones).
<code>\1</code>	Backreference, captura el patrón anterior repetido consecutivamente.



Agrupación de patrones

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización
Lematización
POS tagging
Parsing
Name Entity
Recognition (NER)

Tarea

Los paréntesis `()` *capturan* partes del patrón para poder acceder a ellas por separado.

```
import re

texto = "La fecha es 25/12/2023"
patron = r'\d{2}/\d{2}/\d{4}' # SIN paréntesis
match = re.search(patron, texto)

print(match.group(0)) # "25/12/2023"
```

```
import re

texto = "La fecha es 25/12/2023"
patron = r'(\d{2})/(\d{2})/(\d{4})' # CON paréntesis
match = re.search(patron, texto)

print(match.group(0)) # "25/12/2023" (lo mismo)
print(match.group(1)) # "25" (ahora puedo extraer el día)
print(match.group(2)) # "12" (ahora puedo extraer el mes)
print(match.group(3)) # "2023" (ahora puedo extraer el año)
```



Tutorial: Secuencias especiales

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

\A	Inicio de la string
\b	Frontera de palabra
\w	Cualquier <i>word character</i> , es equivalente a [a-zA-Z0-9_]
\W	Cualquier <i>non word character</i>
\d	Cualquier dígito
\D	Cualquier no dígito



Implementación en Python

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

El módulo `re` de Python proporciona soporte completo para expresiones regulares:

Función	Descripción
<code>search()</code>	Busca la primera coincidencia en cualquier parte de la cadena
<code>match()</code>	Busca coincidencia solo al inicio de la cadena
<code>findall()</code>	Devuelve lista con todas las coincidencias
<code>sub()</code>	Sustituye coincidencias por otro texto



Limitaciones y alternativas

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

Cuándo NO usar regex:

- Parsing de estructuras anidadas (HTML, XML, JSON)
- Validación compleja de sintaxis
- Cuando el rendimiento es crítico en textos grandes
- Patrones que cambian frecuentemente

Alternativas especializadas:

Tarea	Herramienta
HTML/XML	BeautifulSoup, lxml
JSON	json module
CSV	pandas, csv module
URLs	urllib.parse
Fechas	dateutil, datetime
Emails	email.utils



Ejemplo: Cuándo evitar regex

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

Incorrecto - Parsing HTML con regex: Frágil y propenso a errores

```
html = '<div class="data">Valor</div>'
regex_pattern = r'<div class="data">(.*?)</div>'
```

Correcto - Usando herramientas apropiadas:

```
from bs4 import BeautifulSoup
soup = BeautifulSoup(html, 'html.parser')
valor = soup.find('div', class_='data').text
```

Principio clave: Las regex son excelentes para patrones de texto plano, pero no para estructuras complejas que requieren contexto semántico.



Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

Section 2

Procesamiento básico de texto



Corpus

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

Un corpus es una colección de textos que se utilizará para alguna tarea de NLP.



Algunos ejemplos de corpus:

- 20newsgroups
- IMDB
- Project Gutenberg
- OntoNotes 5
- Penn Treebank



Niveles de análisis

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

significados

oraciones

sintagmas

palabras

morfemas

fonemas
sonidos

SINTAXIS

LÉXICO

MORFOLOGÍA

FONOLOGÍA
FONÉTICA

SEMÁNTICA



Nivel: Palabras

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

Palabras

sorpresa

(significado)

Hubo una _____

sorprendente

(significado)

Eso fue muy _____

sorprendentemente

(significado)

Eso fue _____ bueno



Nivel: Sintagmas

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

- Luis lava el coche con este jabón todos los días
- Luis lava el coche con este jabón todos los días
- Luis lava el coche con este jabón todos los días
- Luis lava el coche con este jabón todos los días



Técnicas de preprocesamiento

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

En cualquier aplicación de NLP el preprocesamiento de texto es el primer paso para cualquier técnica de modelado.

- Tokenización
- Lematización
- Stop words removal
- Etiquetado POS
- Etiquetado NER
- Análisis de dependencias



Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización
Lematización
POS tagging
Parsing
Name Entity
Recognition (NER)

Tarea

Subsection 1

Tokenización



Tokenización (Tokenization)

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización
Lematización
POS tagging
Parsing
Name Entity
Recognition (NER)

Tarea

La **tokenización** es el proceso de dividir un texto en unidades más pequeñas llamadas tokens. Estos tokens pueden ser palabras, caracteres, símbolos o frases. La tokenización es un paso fundamental en el procesamiento del texto.



Dificultades en la tokenización

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

Finland's capital	→	Finland Finlands Finland's ?
what're, I'm, isn't	→	What are, I am, is not
Hewlett-Packard	→	Hewlett Packard ?
state-of-the-art	→	state of the art ?
Lowercase	→	lower-case lowercase lower case ?
San Francisco	→	one token or two?
m.p.h., PhD.	→	??



Dificultades en la tokenización

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

French

- *L'ensemble* → one token or two?
 - *L ? L' ? Le ?*
 - Want *l'ensemble* to match with *un ensemble*

German noun compounds are not segmented

- *Lebensversicherungsgesellschaftsangestellter*
- 'life insurance company employee'
- German information retrieval needs **compound splitter**



Dificultades en la tokenización

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)


Tarea

Chinese and Japanese no spaces between words:

- 莎拉波娃现在居住在美国东南部的佛罗里达。
- 莎拉波娃 现在 居住 在 美国 东南部 的 佛罗里达
- Sharapova now lives in US southeastern Florida

Further complicated in Japanese, with multiple alphabets intermingled

- Dates/amounts in multiple formats





Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

Subsection 2

Lematización



Lematización y Stemming

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

La **lematización** es el proceso de reducir una palabra a su forma base (lema). Se utiliza para:

- Reducir la dimensionalidad del espacio de características, al mapear palabras relacionadas a un solo lema.
- Mejorar la precisión de los modelos de lenguaje, al tratar palabras con el mismo significado como una sola entidad.
- Facilitar la comparación y el análisis de textos, al estandarizar la forma de las palabras.

Correr, corre, corriendo, corredor → **correr**

Feliz, felicidad, felices → **feliz**



Stemming

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

El **stemming** es el proceso de reducir las palabras a su raíz o tronco, eliminando sufijos y prefijos. El objetivo es identificar la forma base de una palabra, independientemente de su conjugación, número o género. Se utiliza para:

- Reducir la dimensionalidad del espacio de características en tareas de clasificación de texto.
- Mejorar la eficiencia en la indexación de texto.
- Facilitar la búsqueda de información.

Correr, corre, corriendo, corredor → corri

El stemming puede ser más rápido, aunque menos preciso, que la lematización. Además de producir palabras posiblemente no validas.



Diferencias entre Stemming y Lemmatización

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

Difference between stemming Vs. lemmatization

Stemming	Lemmatization
Stemming is a process that stems or removes last few characters from a word, often leading to incorrect meanings and spelling.	Lemmatization considers the context and converts the word to its meaningful base form, which is called Lemma.
For instance, stemming the word ' Caring ' would return ' Car '.	For instance, lemmatizing the word ' Caring ' would return ' Care '.
Stemming is used in case of large dataset where performance is an issue.	Lemmatization is computationally expensive since it involves look-up tables and what not.



Diferencias entre Stemming y Lematización

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

- **Stemming:**

- "corriendo" → "corr"
- "corrió" → "corr"
- "gatos" → "gat"

- **Lematización:**

- "corriendo" → "correr"
- "corrió" → "correr"
- "gatos" → "gato"



Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

Subsection 3

POS tagging



Etiquetado POS

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging


Parsing

Name Entity
Recognition (NER)

Tarea

El **POS Tagging (Part-of-Speech Tagging)** es el proceso de identificar la categoría gramatical de cada palabra en un texto, como: Sustantivo (NOUN), verbo (VERB), adjetivo (ADJ), etc. El objetivo del POS Tagging es etiquetar cada palabra con su correspondiente categoría gramatical, lo que permite comprender mejor el significado y la estructura del texto.

POS Tagging





Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

Subsection 4

Parsing



Parsing

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización


POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

El **parsing**, también conocido como análisis sintáctico, es el proceso de analizar una secuencia de tokens para determinar su estructura gramatical. En otras palabras, es el proceso de identificar las relaciones entre las palabras o símbolos en una secuencia para entender su significado.





Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

Subsection 5

Name Entity Recognition (NER)



Reconocimiento de Entidades Nombradas

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

NER (Named Entity Recognition) es el proceso de identificar y clasificar entidades nombradas en un texto en categorías pre-definidas como:

- Nombres de personas (PER)
- Nombres de lugares (LOC)
- Nombres de organizaciones (ORG)
- Fechas (DATE)
- Monedas (MONEY)
- ...

El objetivo de NER es extraer información relevante de un texto y clasificarla en categorías significativas para su posterior análisis o procesamiento.



Reconocimiento de Entidades Nombradas

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

ORGANISATION LOCATION DATE PERSON WEAPON

The **ISIS** ORG has claimed responsibility for a suicide bomb blast in the **Tunisian** LOC capital **earlier this week** DATE, the **militant group** ORG 's **Amaq news agency** ORG said on **Thursday** DATE. A **militant** PER wearing an **explosives belt** WEAPON blew himself up in **Tunis** LOC



NLP Pipeline

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización


Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea





Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

Section 3

Tarea



DeepSeek

Procesamiento
de Lenguaje
Natural

Expresiones
regulares

Procesamiento
básico de
texto

Tokenización

Lematización

POS tagging

Parsing

Name Entity
Recognition (NER)

Tarea

Images/deepseek.png